

HealthSense

Customer Health Score com Lógica Fuzzy (Mamdani)

Trabalho	Parte 1 — Sistemas de Controle Fuzzy · Modalidade B (Produto)
Disciplina	Inteligência Artificial e Computacional (0700M8) — CESUPA
Professor	Daniel Leal Souza · Semestre 2026/1
Equipe	[Integrante 1] · [Integrante 2] · [Integrante 3] · [Integrante 4] · [Integrante 5]
Turma	[CC5MA / CC5NA]
Repositório	https://github.com//healthsense

Resumo

Este trabalho apresenta o **HealthSense**, um sistema de apoio à decisão para equipes de Customer Success em SaaS B2B, baseado em controle fuzzy do tipo Mamdani. O sistema combina cinco variáveis linguísticas — engajamento, volume de suporte, satisfação (NPS), saúde financeira e tenure — em um **Customer Health Score (CHS)** de 0 a 100, classificado em cinco níveis (Crítico, Em Risco, Atenção, Saudável e Promotor). A inferência usa operadores de mínimo/máximo e defuzzificação por centróide sobre uma base de **32 regras** com justificativa de domínio. A solução é entregue como um dashboard interativo e validada com 14 cenários de teste e 16 testes automatizados. Como ampliação, realiza-se uma análise de sensibilidade das funções de pertinência; como pontuação extra, os parâmetros das funções são otimizados automaticamente via PSO.

Palavras-chave: lógica fuzzy, sistema Mamdani, Customer Success, SaaS B2B, defuzzificação por centróide.

1. Introdução e motivação

Empresas de software por assinatura (SaaS B2B) vivem de receita recorrente: reter e expandir a base de clientes é mais determinante para o resultado do que apenas adquirir novos. A função de **Customer Success (CS)** existe para isso — acompanhar cada conta para que ela tenha sucesso com o produto, permaneça e cresça. Para priorizar a carteira, as equipes usam um *Customer Health Score*, um indicador que resume a saúde de cada conta.

O problema é como calcular esse indicador. Abordagens tradicionais sofrem de limitações: scores binários (bom/ruim) perdem nuance; somas de pesos fixos são arbitrárias e não capturam interações entre variáveis; e regras rígidas do tipo *se-então* quebram em fronteiras (um atraso de 30 dias seria “em dia” e 31 dias “inadimplente”?). A saúde de um cliente é, por natureza, uma questão de **gradação e incerteza** — exatamente o domínio da lógica fuzzy.

1.1. Justificativa do uso de lógica fuzzy

- **Transições suaves:** 31 dias de atraso é praticamente igual a 30 — sem saltos artificiais.
- **Regras linguísticas:** aderem ao raciocínio do especialista (CSM), em vez de pesos opacos.
- **Combinação não-linear:** variáveis que se compensam são tratadas por uma base de regras.

- **Explicabilidade:** cada score é justificado pelas regras que dispararam — essencial para a confiança do usuário.

1.2. Objetivos

Geral: implementar um sistema fuzzy Mamdani funcional, validado e demonstrável para o cálculo do CHS. **Específicos:** modelar 5 variáveis com universos justificados; construir uma base de regras coerente; entregar um dashboard interativo; validar com cenários típicos e críticos; e, como extra, otimizar os parâmetros das funções de pertinência.

2. Fundamentação teórica

Um **conjunto fuzzy** (Zadeh, 1965) generaliza o conjunto clássico: em vez de pertencer ou não, cada elemento tem um **grau de pertinência** no intervalo $[0, 1]$. Uma **variável linguística** assume valores que são palavras (p. ex. engajamento “Baixo”, “Alto”), cada uma associada a um conjunto fuzzy definido por uma **função de pertinência (MF)** sobre um **universo de discurso**.

Em um **sistema de inferência Mamdani** (Mamdani & Assilian, 1975), a saída é obtida em cinco etapas: (1) **fuzzificação** dos valores de entrada; (2) avaliação dos antecedentes das regras, com o conectivo *E* implementado pelo **mínimo**; (3) **implicação**, recortando o conjunto de saída pelo grau de ativação; (4) **agregação** das saídas de todas as regras pelo **máximo**; e (5) **defuzzificação**, aqui pelo **centróide** (centro de massa), que produz um valor numérico contínuo e estável.

2.1. Trabalhos relacionados

O uso de sistemas fuzzy em problemas de cliente é bem estabelecido. Aplicações a churn em telecom comparam Mamdani e Sugeno destacando a alta interpretabilidade do primeiro; há também modelos fuzzy para Customer Lifetime Value (a partir de RFM), medição de satisfação (CSI) e otimização de atendimento. O presente trabalho adapta essas ideias ao contexto de Customer Health Score em SaaS B2B, com base de regras própria e validação experimental. As referências completas estão na Seção 8.

3. Metodologia e modelagem fuzzy

3.1. Variáveis, universos e termos linguísticos

Variável	Universo (unidade)	Termos linguísticos
Engajamento	0–100 (índice de uso)	Baixo · Moderado · Alto · Muito Alto
Volume de suporte	0–30 (tickets/mês)	Saudável · Atenção · Alto · Crítico
Satisfação (NPS)	0–10 (NPS individual)	Detrator · Neutro · Promotor
Saúde financeira	0–90 (dias de atraso)	Em dia · Atraso leve · Atraso grave
Tenure	0–60 (meses de contrato)	Novo · Estabelecido · Veterano
Saída: CHS	0–100 (score)	Crítico · Em Risco · Atenção · Saudável · Promotor

Tabela 1 — Variáveis de entrada e saída, com universos de discurso e termos linguísticos.

A escolha das cinco variáveis cobre os pilares de um health score na prática de mercado: uso do produto (engajamento), fricção operacional (suporte), percepção (NPS), compromisso financeiro (atraso) e maturidade do relacionamento (tenure). O **tenure** modula a interpretação das demais: o mesmo engajamento baixo significa coisas diferentes em uma conta nova (onboarding) e em uma veterana (risco de não-renovação).

3.2. Funções de pertinência

Adotou-se uma combinação justificada de formatos: **trapezoidais** nos termos extremos (valores muito baixos ou altos devem ter pertinência plena em uma faixa, não em um único ponto); **triangulares** nos termos intermediários (que têm um valor central de referência); e **gaussianas** na saída, para garantir uma superfície de controle suave e defuzzificação por centróide estável. Os parâmetros estão codificados na classe MFParams (arquivo src/fuzzy/membership_functions.py).




Figura 1 — Funções de pertinência da variável Engajamento (0–100).




Figura 2 — Funções de pertinência da saída CHS (gaussianas).

3.3. Base de regras

ID	Categoria	Justificativa (conhecimento de domínio)
R1	CRITICO	Engajamento baixo + tickets críticos = cliente abandonado em meio a problema operacional grave.
R2	CRITICO	Detrator (NPS baixo) com inadimplência grave = vontade explícita de sair + sinal financeiro.
R3	CRITICO	Engajamento baixo + atraso grave = cliente fora da plataforma E inadimplente.
R4	CRITICO	Veterano com baixo engajamento, suporte crítico e detrator = churn iminente de conta estratégica.
R5	RISCO	Veterano com engajamento baixo = lealdade artificial, alto risco de não-renovação.
R6	RISCO	Detrator com alto volume de suporte = frustrado com fricções operacionais.
R7	RISCO	Suporte crítico + atraso leve = dor operacional contagiando saúde financeira.
R8	RISCO	Engajamento moderado + detrator = uso mecânico sem valor percebido.
R9	RISCO	Engajamento baixo em cliente estabelecido = sinal de adoção que estagnou.
R10	RISCO	Veterano detrator = relacionamento azedando após longo histórico.

ID	Categoria	Justificativa (conhecimento de domínio)
R11	ATENCAO	Cliente novo com engajamento moderado = onboarding em progresso, ainda imaturo.
R12	ATENCAO	Engajamento moderado + suporte em atenção = adoção parcial com fricção média.
R13	ATENCAO	Atraso leve + satisfação neutra = cliente sem reclamação mas com sinais financeiros amarelos.
R14	ATENCAO	Cliente novo recebendo muito suporte = onboarding com dificuldade técnica.
R15	ATENCAO	Engajamento alto mas detrator = usa o produto contrariado (alto risco de migração).
R16	ATENCAO	Cliente novo com baixo engajamento = onboarding falhando, intervenção early-stage.
R17	SAUDAVEL	Engajamento alto, satisfação neutra e financeiro em dia = padrão de cliente estável.
R18	SAUDAVEL	Engajamento alto + baixo volume de suporte = adoção saudável e auto-suficiente.
R19	SAUDAVEL	Veterano com engajamento moderado e em dia = padrão maduro, uso eficiente.
R20	SAUDAVEL	Engajamento alto + promotor = cliente satisfeito usando ativamente.
R21	SAUDAVEL	Engajamento muito alto com leve fricção de suporte = power user com ruído normal.
R22	PROMOTOR	Engajamento muito alto + promotor + em dia = perfil ideal para expansão de receita.
R23	PROMOTOR	Engajamento muito alto + promotor + veterano = case de sucesso, candidato a referência.
R24	PROMOTOR	Power user sem suporte e em dia = adoção orgânica, alta autonomia.
R25	PROMOTOR	Veterano promotor com engajamento alto e em dia = relacionamento maduro de valor.
R26	CONFLITO	Power user inadimplente grave = uso ativo não compensa risco financeiro, rebaixa para risco.
R27	CONFLITO	Promotor com suporte crítico = elogio ao produto mas dor operacional aguda, rebaixa para atenção.
R28	CONFLITO	Engajamento moderado + promotor + suporte saudável = cliente satisfeito mesmo com uso parcial.
R29	BASELINE	Sem outros sinais, engajamento baixo é heurística de risco (uso é proxy primário de valor).
R30	BASELINE	Sem outros sinais, engajamento moderado é zona de atenção (adoção parcial).
R31	BASELINE	Sem outros sinais, engajamento alto é heurística de saúde (uso ativo do produto).
R32	BASELINE	Sem outros sinais, engajamento muito alto é heurística de saudável (promoção a 'Promotor' exige sinal explícito de NPS+financeiro nas regras específicas R22-R25).

Tabela 2 — Base completa de 32 regras Mamdani, agrupadas em 7 categorias.

3.4. Mecanismo de inferência

Operadores: **E = mínimo**, **OU = máximo**, **implicação = mínimo**, **agregação = máximo** e **defuzzificação = centróide**. O centróide foi escolhido por produzir uma saída numérica contínua e estável — pequenas variações nas entradas geram pequenas variações no CHS — mais adequada a um índice do que métodos como a Média dos Máximos (MOM), que produziria saltos. As regras de categoria **Baseline** (R29–R32) garantem que qualquer entrada ative ao menos uma regra, eliminando “buracos” no espaço.

4. Implementação

O sistema é implementado em Python com a biblioteca `scikit-fuzzy` como motor de inferência. A arquitetura separa a modelagem (variáveis e funções de pertinência), a base de regras e o motor de avaliação, expostos por uma API simples e consumidos por um dashboard interativo em Streamlit.

- `src/fuzzy/membership_functions.py` — variáveis, universos e funções de pertinência (MFPParams).
- `src/fuzzy/rules.py` — base de 32 regras com justificativa.
- `src/fuzzy/fuzzy_engine.py` — motor Mamdani, avaliação, graus de ativação e superfícies de controle.
- `app/pages/1_Customer_Health_Score.py` — dashboard (sliders, gauge do CHS, regras ativadas, superfícies).

A reprodutibilidade é garantida por `requirements.txt`, um manual de execução (`docs/manual_execucao.md`) e scripts em `experiments/` que regeneram todas as figuras e tabelas. O código está versionado no repositório indicado na capa.

5. Experimentos e resultados

5.1. Cenários de teste

ID	Cenário	Entradas (eng/su p/nps/atr/ten)	CH S	Classe	Interpretação / coerência
C01	Crítico — abandonado e inadimplente	5/2/3/60/18	22	Em Risco	Uso quase nulo e 60 dias de atraso; corretamente classificado no extremo inferior.
C02	Crítico — explosão de tickets	15/25/2/10/24	22	Em Risco	25 tickets e detrator: fricção operacional aguda leva a Em Risco.
C03	Crítico — veterano que parou	10/5/4/20/48	22	Em Risco	Lealdade não sustenta uso quase nulo; veterano é rebaixado, como esperado.
C04	Atenção — novo em onboarding	45/6/7/0/2	50	Atenção	Uso parcial é normal para conta nova; resultado intermediário coerente.
C05	Atenção — uso estagnado	42/4/7/8/15	50	Atenção	Cliente morno, sem reclamar: zona de monitoramento.
C06	Atenção — engajado mas detrator	75/3/3/0/20	60	Atenção	Usa muito porém insatisfeito (risco de migração); não é Saudável pleno.
C07	Promotor — power user ideal	95/1/10/0/42	78	Saudável	Todos os sinais altos; topo da escala, como esperado.
C08	Saudável — conta normal	72/3/8/2/24	70	Saudável	Bom uso e satisfação: estado saudável estável.
C09	Promotor — recente animado	88/2/10/0/6	78	Saudável	NPS alto e forte uso já cedo; resultado elevado coerente.
C10	Fronteira — atenção/saudável	60/5/7/5/18	61	Saudável	Valores médios-altos; cai na faixa de transição.
C11	Fronteira — risco/atenção	35/8/6/15/12	50	Atenção	Sinais amarelos; transição inferior, coerente.
C12	Fronteira — saudável/promotor	82/2/9/0/30	78	Saudável	Quase ideal; topo de Saudável.
C13	Conflito — power user inadimplente	92/1/8/75/24	50	Atenção	Usa muito mas 75 dias de atraso: regra de conflito rebaixa — uso não compensa risco.
C14	Conflito — promotor com suporte crítico	70/22/10/0/18	61	Saudável	Ama o produto mas 22 tickets: rebaixado da faixa de promotor, coerente.

Tabela 3 — 14 cenários de teste: entradas, saída do sistema, classificação e comentário de coerência. Todos os 16 testes automatizados (pytest) passam.

5.2. Superfície de controle

A superfície de controle mostra como o CHS varia ao cruzar duas variáveis, mantendo as demais fixas — evidência de que o sistema responde de forma coerente e suave, sem descontinuidades.




Figura 3 — Superfície de controle: CHS em função de engajamento × satisfação.

5.3. Análise de sensibilidade (ampliação)

Como ampliação obrigatória da equipe de 5, variou-se o centro da função de pertinência *engajamento_alto* e mediu-se o CHS médio em 100 personas sintéticas. O resultado confirma que a calibração das funções tem impacto mensurável no comportamento global — o que motiva a otimização automática.




Figura 4 — Sensibilidade do CHS médio ao centro da MF engajamento_alto.

5.4. Otimização por PSO (pontuação extra)

Como extensão, aplicou-se **Particle Swarm Optimization** para ajustar automaticamente os parâmetros das funções de pertinência da saída, minimizando o erro entre o CHS do sistema e rótulos de especialista em um conjunto de personas. A figura compara o erro por persona antes e depois da otimização.



Figura 5 — Erro por pessoa: baseline vs. parâmetros otimizados por PSO.

6. Discussão e limitações

O sistema comporta-se de forma coerente em toda a faixa de operação, incluindo casos de conflito (R13, R14), em que regras de exceção evitam classificações absurdas. As superfícies de controle confirmam suavidade, e a análise de sensibilidade evidencia quais parâmetros são mais influentes.

- **Sensibilidade à calibração:** os parâmetros refletem práticas de mercado e exigem recalibração por contexto — daí o valor da otimização por PSO.
- **Dados sintéticos:** a validação usa personas sintéticas; uma validação com dados reais é trabalho futuro.
- **Apoio à decisão:** o CHS é uma recomendação interpretável, não um diagnóstico determinístico — o CSM permanece no comando.

7. Conclusão e trabalhos futuros

O HealthSense entrega um sistema fuzzy Mamdani coerente, validado e explicável, como produto demonstrável. Ele traduz cinco sinais difusos em um score acionável, com regras que um humano entende. Como continuidade (Parte 2), este motor é reutilizado como função de aptidão de um otimizador evolutivo que decide o plano de ação do time de CS. Outros trabalhos futuros incluem integração com CRMs e auto-rotulagem de clientes por aprendizado supervisionado.

8. Declaração de uso de IA

O uso de IA está declarado em detalhe no documento docs/declaracao_uso_ia.md. Em síntese: ferramentas de IA apoiaram o esboço de código, sugestões de regras e revisão textual; todo o material foi revisado, executado e validado pela equipe, que assume responsabilidade pelo conteúdo final.

9. Referências

- 1 ZADEH, L. A. Fuzzy sets. *Information and Control*, v. 8, n. 3, p. 338–353, 1965.
- 2 MAMDANI, E. H.; ASSILIAN, S. An experiment in linguistic synthesis with a fuzzy logic controller. *International Journal of Man-Machine Studies*, v. 7, n. 1, p. 1–13, 1975.
- 3 KLIR, G. J.; YUAN, B. *Fuzzy Sets and Fuzzy Logic: Theory and Applications*. Prentice Hall, 1995.
- 4 KENNEDY, J.; EBERHART, R. Particle swarm optimization. In: *Proc. IEEE Int. Conf. on Neural Networks*, 1995.

- 5 Optimizing Customer Retention in the Telecom Industry: A Fuzzy-Based Churn Modeling with Usage Data. *Electronics* (MDPI), v. 13, n. 3, 469, 2024. Disponível em: <https://www.mdpi.com/2079-9292/13/3/469>
- 6 Fuzzy Logic and Decision Making Applied to Customer Service Optimization. *Axioms* (MDPI), v. 12, n. 5, 448, 2023. Disponível em: <https://www.mdpi.com/2075-1680/12/5/448>
- 7 Measuring Customer Satisfaction Using a Fuzzy Inference System. *Journal of Applied Sciences*, 2009. Disponível em: <https://scialert.net/fulltext/?doi=jas.2009.469.478>
- 8 Churn prediction for SaaS company with machine learning. *Innovation & Management Review* (Emerald), v. 22, n. 2, 2025.
- 9 scikit-fuzzy — Fuzzy Logic Toolkit for SciPy. Disponível em: <https://pythonhosted.org/scikit-fuzzy/>
- 10 Streamlit — The fastest way to build data apps. Disponível em: <https://docs.streamlit.io/>