

Relatório Técnico — Otimização por Enxame de Partículas (PSO)

Calibração automática das funções de pertinência do Customer Health Score

Contexto	HealthSense · Parte 1 (Fuzzy) · Pontuação extra
Disciplina	Inteligência Artificial e Computacional (0700M8) — CESUPA · Prof. Daniel Leal Souza
Equipe	João Felipe Soares · Pedro Lyra · Paulo Ricardo · Murilo Carneiro · Vithor dos Santos
Código	experiments/parte1_pso.py · Biblioteca: PySwarms (GlobalBestPSO)

1. O que é o PSO e por que usá-lo aqui

O **PSO (Particle Swarm Optimization — Otimização por Enxame de Partículas)** é uma metaheurística bioinspirada, proposta por Kennedy e Eberhart (1995), que imita o comportamento de um bando — pássaros ou cardumes — em busca de comida. Um conjunto de **partículas** sobrevoa o espaço de soluções; cada uma lembra a melhor posição que já encontrou (**pbest**) e todas compartilham a melhor posição já vista pelo enxame (**gbest**). A cada passo, cada partícula ajusta sua trajetória combinando sua inércia, sua memória pessoal e a influência social do grupo — e o enxame converge para boas regiões do espaço.

O **problema que resolvemos com ele**: o sistema fuzzy de Customer Health Score tem parâmetros nas suas funções de pertinência — em particular, **onde cada faixa de saúde está centrada**. Esses valores eram definidos manualmente, por intuição. O PSO os **calibra automaticamente**, buscando a configuração que faz o sistema reproduzir melhor o julgamento de um especialista.

2. Formulação do problema de otimização

2.1. Variável de decisão (a partícula)

Cada partícula é um **vetor de 5 números reais**, os centros das gaussianas de saída do CHS:

`x = [ c_Crítico , c_EmRisco , c_Atenção , c_Saudável , c_Promotor ]`

Ou seja, o PSO procura no **espaço de 5 dimensões** a melhor posição para essas cinco faixas.

2.2. Espaço de busca (restrições / bounds)

Cada centro é limitado a uma faixa plausível, preservando a ordem das categorias:

Centro	Crítico	Em Risco	Atenção	Saudável	Promotor
Limite inferior	0	15	35	55	75
Limite superior	20	45	65	85	100

Tabela 1 — Limites do espaço de busca para cada centro de gaussiana.

2.3. Função objetivo (o que minimizamos)

Usamos um conjunto de **10 personas rotuladas por especialista** (cliente → CHS esperado). Para uma partícula *x*, construímos o sistema fuzzy com aqueles centros, calculamos o CHS de cada persona e medimos o **erro médio absoluto (MAE)** contra o rótulo do especialista:

$$f(x) = (1/N) \cdot \sum | \text{CHS_fuzzy}(\text{persona_i} ; x) - \text{CHS_esperado_i} |$$

O objetivo do PSO é **minimizar $f(x)$** — quanto menor, mais o sistema concorda com o especialista.

2.4. Critério de parada

Número fixo de iterações (30), suficiente para o enxame estabilizar neste problema de baixa dimensão.

3. Parâmetros do PSO (e justificativa)

Parâmetro	Valor	Papel / justificativa
Nº de partículas	20	Enxame suficiente para 5 dimensões sem custo excessivo
Dimensões	5	Os 5 centros de gaussiana otimizados
Iterações	30	Convergência estável neste problema
Inércia (w)	0,7	Equilíbrio entre exploração e exploração
Cognitivo ($c1$)	1,5	Peso da melhor posição pessoal (pbest)
Social ($c2$)	1,5	Peso da melhor posição global (gbest)

Tabela 2 — Configuração do PySwarms (GlobalBestPSO).

4. Como o PSO funciona, passo a passo

- Inicialização:** 20 partículas recebem posições aleatórias dentro dos limites, com velocidades pequenas.
- Avaliação:** para cada partícula, monta-se o sistema fuzzy e calcula-se $f(x)$, o erro médio contra as 10 personas.
- Memória:** cada partícula guarda sua melhor posição já vista (pbest); o enxame guarda a melhor de todas (gbest).
- Atualização de velocidade:** cada partícula combina inércia + atração para o pbest + atração para o gbest.
- Atualização de posição:** a partícula se move pela nova velocidade, dentro dos limites.
- Iteração:** repete avaliação → memória → movimento por 30 passos, até o gbest estabilizar.

As equações que regem o movimento de cada partícula i (PSO de melhor global):

$$v(t+1) = w \cdot v(t) + c1 \cdot r1 \cdot (pbest - x) + c2 \cdot r2 \cdot (gbest - x)$$

$$x(t+1) = x(t) + v(t+1)$$

onde w controla a inércia, $c1$ a atração à memória pessoal, $c2$ a atração ao melhor do grupo, e $r1, r2$ são números aleatórios em $[0,1]$ que dão a aleatoriedade exploratória.

5. Resultados reais

Partindo da configuração manual (baseline), o erro médio absoluto era de **5.69 pontos** de CHS. Após a calibração pelo PSO, o erro caiu para **3.94 pontos** — uma **redução de 30.8%**. Ou seja, o sistema passou a concordar mais com o especialista, sem qualquer ajuste manual.

	Erro médio (MAE)	Interpretação
Baseline (manual)	5.69	Parâmetros definidos por intuição
Otimizado (PSO)	3.94	Calibração automática · -30.8%

Tabela 3 — Erro médio absoluto antes e depois da otimização por PSO.

5.1. Erro por persona (antes vs depois)

Persona	CHS esperado	Baseline	Otimizado	Erro base	Erro otim.
P01	92	78.5	78.9	13.5	13.1
P02	82	78.4	78.8	3.6	3.2
P03	70	70.0	70.2	0.0	0.2
P04	60	61.3	60.1	1.3	0.1
P05	50	50.0	47.0	0.0	3.0
P06	48	50.0	47.0	2.0	1.0
P07	38	50.0	47.0	12.0	9.0
P08	12	21.5	13.8	9.5	1.8
P09	10	21.5	13.8	11.5	3.8
P10	18	21.5	13.8	3.5	4.2

Tabela 4 — CHS esperado vs. produzido (baseline e otimizado) e erros, por persona.




Figura 1 — Curva de convergência: o erro médio cai a cada iteração do enxame.




Figura 2 — Erro por persona: baseline (vermelho) vs. otimizado por PSO (verde).

6. Discussão, limitações e conexão com o projeto

- **Por que PSO e não Algoritmo Genético?** O espaço aqui é **contínuo** (parâmetros reais das gaussianas) — terreno natural do PSO. Na Parte 2, o espaço é combinatório e usamos AG. Ferramenta certa para cada problema.

- **Papel invertido das técnicas:** aqui a evolução (PSO) **calibra** o fuzzy; na Parte 2 o fuzzy **é a função de aptidão** do AG. O mesmo casamento, em direções opostas.
- **Limitações:** otimizamos apenas os centros das gaussianas de saída (não as larguras nem as MFs de entrada); o conjunto de rótulos é pequeno (10 personas). Ampliar ambos é trabalho futuro.
- **Reprodutibilidade:** todo o experimento está em `experiments/parte1_pso.py` e os dados em `data/pso_antes_depois.csv`.